Predicción de satisfacción de pasajeros en aerolíneas

- Este proyecto presenta el desarrollo de un modelo de Machine Learning supervisado orientado a predecir la satisfacción de pasajeros en aerolíneas.

OBJETIVO DEL PROYECTO

- El objetivo principal es construir un modelo capaz de anticipar si un pasajero estará satisfecho con su experiencia de vuelo. Para ello, se comparan distintos enfoques y se optimiza el rendimiento mediante técnicas de ajuste de hiperparámetros.

Carga y exploración de datos

- Lectura de datasets: train y test
  - Limpieza y tratamiento de variables de ambos datasets
- Distribución de la variable objetivo
  - Mapa de calor de correlaciones
  - Identificación de variables relevantes

División del dataset

- Train/Test Split (80% / 20%)
  - Stratificación por variable objetivo

Pipeline de procesamiento de datos

- Implementación de ColumnTransformer: Tratamiento diferenciado por tipo de variable en un solo flujo atómico.
- Bloque Numérico:
  - Imputación: Manejo de valores nulos en Arrival Delay utilizando la mediana para mitigar el impacto de outliers.
  - Escalado: Uso de StandardScaler para normalizar magnitudes (Edad, Distancia) y equilibrar el peso de las features.
- Bloque Categórico:Encoding: Aplicación de OneHotEncoder para convertir variables de texto (Class, Type of Travel) en vectores numéricos procesables.Garantía Técnica: Eliminación de riesgos de Data Leakage al ajustar las transformaciones exclusivamente con los datos de entrenamiento.

Automatización y robustez

- Integración Modelo-Preprocesado: El modelo Random Forest se integra directamente al final del Pipeline, creando un objeto de predicción "llave en mano".
- Consistencia de Datos: Asegura que los datos de Test pasen exactamente por el mismo proceso que los de Train, evitando errores de formato o dimensiones.
- Persistencia con Joblib: Exportación del sistema completo a un archivo binario .joblib.
  - Permite cargar en segundos todo el conocimiento: escalas, categorías y pesos del modelo.
- Escalabilidad: Sistema preparado para inferencia inmediata sobre datos en bruto (Raw Data), facilitando su despliegue en entornos reales.

MODELO BASELINE - LOGISTIC REGRESSION

- Se implementó una regresión logística como modelo base para establecer una referencia de desempeño. Sus métricas permiten evaluar posteriormente la mejora obtenida con modelos más complejos.

```
--- RESULTADOS BASELINE (Logistic Regression) ---
              precision    recall  f1-score   support

           0       0.88      0.89      0.88     14690
           1       0.85      0.84      0.85     11286

    accuracy                           0.87     25976
   macro avg       0.86      0.86      0.86     25976
weighted avg       0.87      0.87      0.87     25976
```

MODELO AVANZADO - RANDOM FOREST

- Se entrenó un modelo Random Forest, capaz de capturar relaciones no lineales y patrones complejos en los datos. Este enfoque mostró un desempeño superior al modelo baseline.

```
RESULTADOS MODELO AVANZADO (Random Forest)
              precision    recall  f1-score   support

           0       0.95      0.98      0.97     14690
           1       0.97      0.94      0.95     11286

    accuracy                           0.96     25976
   macro avg       0.96      0.96      0.96     25976
weighted avg       0.96      0.96      0.96     25976
```

OPTIMIZACIÓN DEL MODELO

- SE APLICÓ RANDOMIZEDSEARCHCV PARA IDENTIFICAR LA MEJOR COMBINACIÓN DE HIPERPARÁMETROS. MEDIANTE VALIDACIÓN CRUZADA SE SELECCIONÓ EL MODELO CON MAYOR CAPACIDAD PREDICTIVA.

```
--- EVALUACIÓN FINAL (Modelo Optimizado) ---
              precision    recall  f1-score   support

           0       0.95      0.98      0.97     14690
           1       0.97      0.94      0.96     11286

    accuracy                           0.96     25976
   macro avg       0.96      0.96      0.96     25976
weighted avg       0.96      0.96      0.96     25976
```

EVALUACIÓN FINAL

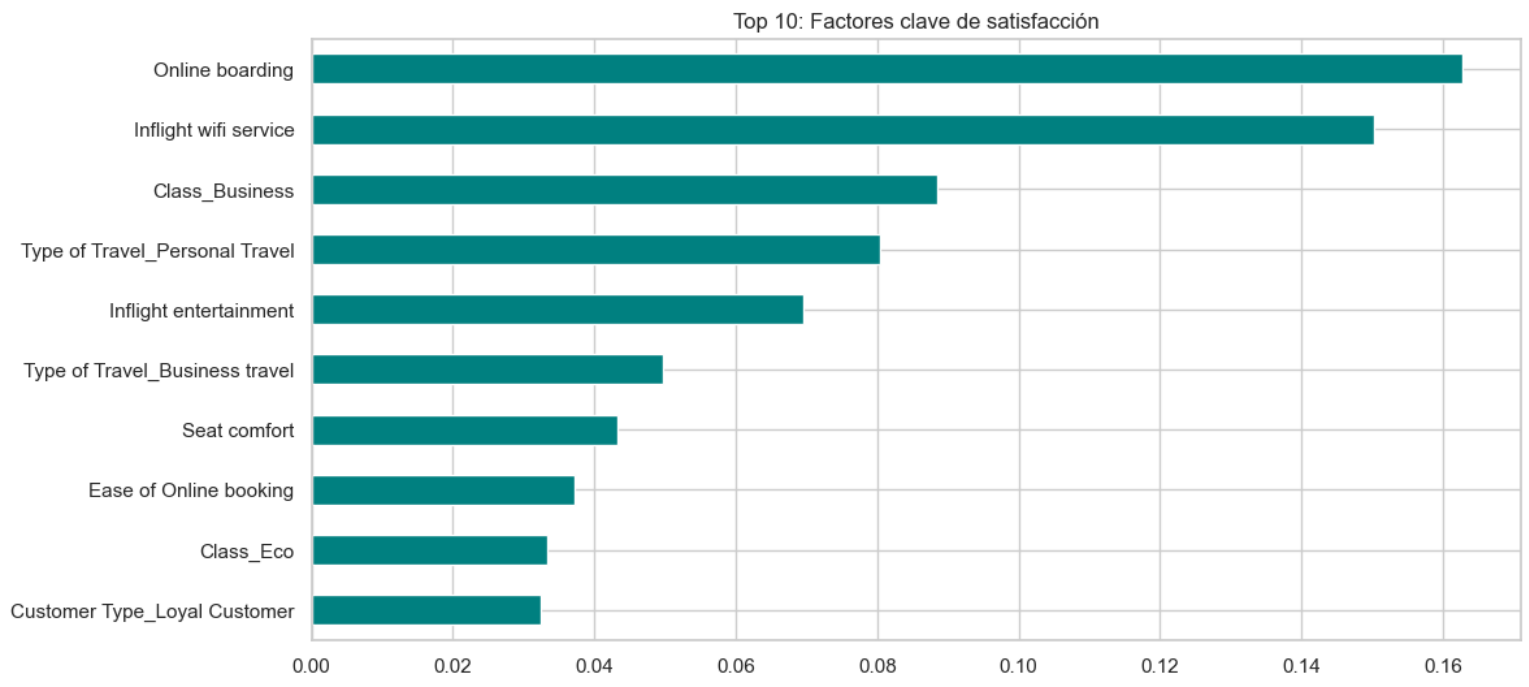

FEATURE IMPORTANCE

- Extracción de importancia de variables
  - Top 15 features más influyentes
  - Visualización mediante gráfico horizontal
  - Interpretación del impacto en satisfacción

ANÁLISIS DE PROBABILIDADES

- EVALUACIÓN DE NIVEL DE CONFIANZA
- CLASIFICACIÓN EN ALTA CONFIANZA Y DUDOSAS
- ANÁLISIS DE CASOS AMBIGUOS

```
PRIMERAS 10 PREDICCIONES CON PROBABILIDADES
==============================================================================
   Predicción  Probabilidad_No_Satisfecho  Probabilidad_Satisfecho  Verdadera_Clase
0           0                   0.941310                 0.058690                0
1           0                   0.997500                 0.002500                0
2           1                   0.009137                 0.990863                1
3           0                   0.995000                 0.005000                0
4           1                   0.000000                 1.000000                1
5           0                   0.999000                 0.001000                0
6           1                   0.000000                 1.000000                1
7           0                   0.930833                 0.069167                0
8           1                   0.000000                 1.000000                1
9           0                   0.997500                 0.002500                0

✓ Predicciones con alta confianza (>90%): 21127 (81.33%)
⚠️  Predicciones dudosas (50-70%): 1817 (6.99%)
```

```
Primeros casos DUDOSOS (confianza 50-70%):
     Predicción  Probabilidad_Satisfecho  Verdadera_Clase
32            0                 0.346284                1
47            1                 0.575974                0
55            0                 0.347399                0
60            0                 0.335570                1
91            1                 0.544486                0
96            0                 0.302258                1
129           1                 0.542353                1
158           0                 0.389899                0
160           1                 0.574119                1
163           0                 0.494089                0
```

CONCLUSIONES

- Random Forest supera al baseline
  - La optimización mejora el rendimiento
  - Variables clave influyen significativamente en satisfacción
  - Modelo listo para integración o despliegue